

Laboratorio 2 - Biblical Text Mining

Nombre: Juan Francisco Maltés

Profesor: Cristhian Rabi

Programación Científica

Contexto y datos

El conjunto de datos seleccionado para este proyecto corresponde al texto completo de la Biblia. Desde la perspectiva del Procesamiento del Lenguaje Natural (NLP), este corpus presenta tres características fundamentales que condicionan el comportamiento de los modelos estadísticos.

En primer lugar, el texto destaca por su alta riqueza léxica. El vocabulario es sumamente extenso y especializado, ya que cuenta con una gran cantidad de nombres propios antiguos, términos teológicos específicos y variaciones idiomáticas derivadas de traducciones históricas. Esto genera un vocabulario muy amplio que requiere un proceso riguroso de limpieza y filtrado de palabras vacías (stopwords).

En segundo lugar, se observa una marcada heterogeneidad de estilos o variabilidad sintáctica. El texto carece de uniformidad estructural debido a que transiciona constantemente entre distintos géneros literarios, como poesía en Salmos, marcos legales en Levítico, narrativa histórica en Génesis y epístolas en las Cartas. Cada género utiliza patrones gramaticales y distribuciones de palabras totalmente distintas, lo que afecta directamente la coherencia de los modelos de generación basados en N-gramas que intentan replicar este comportamiento.

Por último, existe un desbalance extremo de clases, expresado en una disparidad masiva en la longitud de los libros. Mientras que clases mayoritarias como Salmos aportan más de mil versículos al entrenamiento, clases minoritarias como Abdías cuentan con apenas veintiuno. Este desbalance es crítico para el desarrollo del informe, ya que puede inducir un sesgo en el clasificador supervisado, forzando a evaluar el rendimiento real mediante matrices de confusión en lugar de confiar en un simple indicador de accuracy general.

Variables y decisiones del modelo

- **Corpus elegido:** Se escogió el corpus de la biblia en inglés, específicamente el corpus en Inglés Basico (BBE).
- **Estructura de Clases:** Para modularizar el proyecto y facilitar el manejo de la jerarquía de la biblia, se usaron clases para cada elemento dentro de esta; Testamento, Libro, Capitulo y Versos.
- **Listado de Stopwords:** Para las stopwords se usó un listado simple obtenido en Internet, sin embargo se agregaron palabras vacías que tomaban mucha importancia en los CloudWords.

Visualización y Análisis exploratorio

- **Cantidad de versículos por libro:** Como se puede observar (Figura 1), existe una diferencia notable en la cantidad de versículos entre el Antiguo Testamento (que abarca hasta el libro 39, Malachi) y el Nuevo Testamento. Asimismo, dentro de cada testamento, el volumen de versículos también varía de forma considerable entre un libro y otro.




Figure 1: Cantidad de versículos v/s Libro.

- **Heatmap de similitud por Libro:** En la matriz de similitud de libro por libro(Figura 2), se observa claramente la distinción entre libros del Nuevo y Antiguo testamento. El cuadrante superior izquierdo corresponde a la similitud entre los propios libros del Antiguo testamento, en esta zona se observan más áreas oscuras, a diferencia del cuadrante superior derecho, donde las similitudes disminuyen considerablemente entre libros del antiguo y nuevo testamento, y la zona se observa más amarilla. Este comportamiento se repite en el cuadrante inferior derecho, donde se encuentran los libros del Nuevo Testamento, sin embargo, a diferencia de la similitud entre libros del Antiguo testamento, acá la zona oscura es más uniforme y marcada y existen pocos matices amarillos claros, lo que indicaría que los textos son mucho más similares en cuanto a su vocabulario.




Figure 2: Heatmap de similitud entre libros

- **Nube de palabras, Antiguo y Nuevo Testamento:** En las nubes de palabras (Figura 3 y Figura 4) es posible comparar las diferencias principales en vocabulario y del contexto en el cual fueron escritos. En ambos testamentos se ve que las frases más repetidas son, "Lord", "God", sin embargo llama la atención aquellas palabras que no se ven de gran tamaño en la nube o bien algunas que directamente no aparecen en la nube del otro testamento, este es el caso de la palabra "Israel" que aparece de las más importantes en la nube del antiguo testamento pero ni siquiera aparece en la nube del nuevo testamento, mientras que la palabra "Jesus" es de las principales en el nuevo testamento, mientras que en el antiguo no aparece. Estas diferencias, junto a los datos historicos nos permite entender de mejor manera el contexto en el que fueron escritos ambos textos.



Figure 3: Nube de palabras Antiguo Testamento.




Figure 4: Nube de palabras Nuevo Testamento.

- **Distribución de Longitud por versículo:** A través del análisis de distribución de longitud por versículo es posible determinar su extensión promedio. En el gráfico correspondiente (Figura 5), se observa una asimetría negativa (hacia la izquierda). Esto indica que los versículos con una longitud superior a las 15 palabras son una minoría, lo que sugiere un estilo de escritura predominantemente poético o sentencioso. Esta estructura resulta sumamente coherente con la naturaleza del texto bíblico, caracterizado por el uso de máximas y enunciados directos.




Figure 5: Distribución de longitud por versículo.

- **Visualización de versículos mediante PCA:** La visualización de versículos (Figura 6) mediante PCA nos entrega una distribución clara y acorde a lo que se espera de ambos testamentos. En cuanto al nuevo testamento (Puntos azules) se observa que están todos en una zona cercana entre ellos, lo que sugiere que existe un estilo de escritura similar, es decir, homogeneidad léxica. Esta cercanía entre los puntos se entiende al saber que fue escrita en un período de tiempo menor que el antiguo testamento y además tienen una temática similar que es la vida de Jesús. En cuanto a los versículos del antiguo testamento (Puntos naranjas) se ve que están distribuidos a lo largo del gráfico, a veces muy distante entre ellos, lo que indica una heterogeneidad léxica y de estilos de escritura, esto se puede entender también por que fue escrito en un periodo largo de tiempo y trata temas muy diferentes entre libros y capítulos.




Figure 6: Visualización de versículo mediante PCA.

Motor de búsqueda semántico

- **Búsqueda usando Frase:** La frase utilizada fue "God love us all", es una frase típica en religión cristiana, por lo tanto es de esperar que se encuentren frases similares. Todos los resultados que se observan (Figura 7) son del nuevo testamento. Esto se puede interpretar con el cambio de testamento y la forma de referirse a Dios, en el antiguo testamento lo que se indicaba era tomado como ley, orden, los mandamientos y el

juicio que habría de no cumplir con estos dichos, sin embargo en el nuevo testamento la referencia a Dios es con el amor y la gracia.

```

1)Frase
2)Versiculo
3)Salir
Ingresar Frase: God love us all
Ranking: 1
Testamento: New Testament
Libro: 1 John
Capitulo: 4
Verso: 16
Texto Original: And we have seen and had faith in the love which God has for us. God is love, and everyone who has love is in God, and God is in him
Similitud: 0.8373

Ranking: 2
Testamento: New Testament
Libro: 1 John
Capitulo: 4
Verso: 12
Texto Original: No man has ever seen God: if we have love for one another, God is in us and his love is made complete in us:
Similitud: 0.7872

Ranking: 3
Testamento: New Testament
Libro: 1 John
Capitulo: 4
Verso: 10
Texto Original: And this is love, not that we had love for God, but that he had love for us, and sent his Son to be an offering for our sins.
Similitud: 0.7786

Ranking: 4
Testamento: New Testament
Libro: 1 John
Capitulo: 4
Verso: 8
Texto Original: He who has no love has no knowledge of God, because God is love.
Similitud: 0.7727

Ranking: 5
Testamento: New Testament
Libro: 1 John
Capitulo: 4
Verso: 11
Texto Original: My loved ones, if God had such love for us, it is right for us to have love for one another.
Similitud: 0.7481

```

Figure 7: Top 5 versículos similares - Frase.

- **Búsqueda usando Versiculo:** Al analizar por versículo, los resultados de similitud normalmente indican, en el top 5, versículos del mismo testamento, lo que tiene sentido con el análisis que se lleva hasta ahora, esto se puede explicar con el estrilo de escritura de cada uno y el uso de un vocabulario distinto. Al comparar un versiculo del antiguo testamento (Figura 8), se puede ver que el top 5 de versículos, ninguno alcanza el 0.5 de similitud, también corroborando lo diverso lexicamente que fue el antiguo testamento.

```

Ranking: 1
Testamento: Old Testament
Libro: Joshua
Capitulo: 24
Verso: 4
Texto Original: And to Isaac I gave Jacob and Esau: to Esau I gave Mount Seir, as his heritage; but Jacob and his children went down to Egypt.
Similitud: 0.4810

Ranking: 2
Testamento: Old Testament
Libro: Genesis
Capitulo: 33
Verso: 16
Texto Original: So Esau, turning back that day, went on his way to Seir.
Similitud: 0.3751

Ranking: 3
Testamento: Old Testament
Libro: Ezekiel
Capitulo: 35
Verso: 15
Texto Original: You will become a waste, O Mount Seir, and all Edom, even all of it: and you will be certain that I am the Lord.
Similitud: 0.3612

Ranking: 4
Testamento: Old Testament
Libro: Deuteronomy
Capitulo: 2
Verso: 4
Texto Original: And give the people orders, saying, You are about to go through the land of your brothers, the children of Esau, who are living in Seir; and they will have fear of you; so take care what you do:
Similitud: 0.3600

Ranking: 5
Testamento: Old Testament
Libro: Genesis
Capitulo: 33
Verso: 9
Texto Original: But Esau said, I have enough; keep what is yours, my brother, for yourself.
Similitud: 0.3584

```

Figure 8: Top 5 versículos similares - Versículo.

Clasificador de versículos

- **Versículo 1:** El versículo escogido fue: Antiguo Testamento, Exodo, Capitulo 6, Versículo 3. "I let myself be seen by Abraham, Isaac, and Jacob, as God, the Ruler of all; but they had no knowledge of my name Yahweh." Y los resultados (Figura 9), demuestran que el clasificador determinó correctamente el testamento, sin embargo predijo que el libro era Psalms.




Figure 9: Clasificador Versículos - Ejemplo 1.

- Versículo 2:** El versículo escogido fue: Nuevo Testamento, Jhon, Capítulo 17, Versículo 1. "Jesus said these things; then, lifting his eyes to heaven, he said, Father, the time has now come; give glory to your Son, so that the Son may give glory to you". El clasificador (Figura 10) en este caso también determinó que el libro era Psalms, lo que se puede explicar con el hecho de que la frase sea genérica y use palabras que son más comunes en el antiguo testamento, además, Psalms es notoriamente el libro con mas versículos por lo que probabilísticamente tiene una ventaja por sobre los demás al evaluar un versículo, esto sumado a lo genérico de la frase puede significar una mala clasificación. En este clasificador se utilizó el modelo multinomial Naive Bayes, que calcula predicción usando la probabilidad de palabras dado un libro y la probabilidad del libro. Salmos al tener más de 2.400 versículos, genera un efecto de imán para las predicciones, es decir por un desbalance de clases.




Figure 10: Clasificador Versículos - Ejemplo 2.

Generador de texto

- **N-Gram extra:** En ambos casos, el n-grama a elección fue 4. Los resultados se ven en la Figura 11 y Figura 12.

```

---- TESTING GENERATOR ----
1-Gram (Unigram):
god offering unclean offering us hundred

2-Gram (Bigram):
god ear sharp edge moab

3-Gram (Trigram):
spirits god seven stars mouth sharp two-edged sword face like sun going strength forty years

4-Gram (Quadgram):
faces worship god seated high

```

Figure 11: Generador de texto - "God".

```

---- TESTING GENERATOR ----
1-Gram (Unigram):
love right keep armies sons see payments songs rulers keep ruler less lord years wasted place men like get wonder

2-Gram (Bigram):
love bitter plants field food still farther foolish thing representatives far wide poor evil-doer lets get directions way life nets

3-Gram (Trigram):
says love god

4-Gram (Quadgram):
one goes love payment payment different

```

Figure 12: Generador de texto - "Love".

- **UniGram:** No existe ningún tipo de gramática ni estructura. El modelo elige cada palabra basándose únicamente en su frecuencia global en la Biblia sin importar lo que escribió antes. Por esta razón las frases carecen de rumbo y suelen repetir palabras comunes de forma aleatoria (como offering o keep).

- **BiGram:** Mejora sutilmente la conexión entre los pares de palabras adyacentes ("sharp edge", "love bitter"), pero el sentido global se destruye rápidamente. Al mirar una palabra atrás, el modelo cambia de tema constantemente y salta de una idea a otra de forma aleatoria.
- **TriGram:** Aquí el texto empieza a sonar natural. Al recordar las dos palabras anteriores, el modelo es capaz de arrastrar el contexto y recrear imágenes bíblicas (como la simbología apocalíptica en el ejemplo de "god"). El problema es que si la combinación es común, el riesgo de chocar con un "END" es alto, dejando frases muy cortas ("says love god").
- **QuadGram:** Las oraciones son gramaticalmente correctas pero muy cortas. Esto ocurre porque un historial de tres palabras anteriores es muy específico y el modelo "memoriza" y copia fragmentos exactos de la Biblia original. Al quedarse rápido sin opciones para inventar nuevos caminos, se ve obligado a seleccionar el token de "STOP".

Análisis de Sentimiento

- **Herramienta de análisis: VADER**
- **Libros más positivos:** El Top 5 está dominado exclusivamente por cartas del Nuevo Testamento (epístolas como 3 Juan, 2 Juan, Filipenses, Filemón y Tito). Al ser correspondencia personal dirigida a las primeras iglesias, su vocabulario está saturado de términos sumamente positivos según VADER, como amor, gracia, paz, gozo y hermandad.
- **Libros más negativos:** En el otro extremo, encontramos exclusivamente textos del Antiguo Testamento, específicamente a los Profetas Menores (Sofonías, Miqueas, Amós), Jeremías y Lamentaciones. Este bloque concentra los puntajes más bajos debido a su temática central: advertencias de juicio, destrucción militar, ira divina y el luto por el exilio, utilizando palabras de fuerte carga negativa.




Figure 13: Clasificación de sentimiento por libro.

- **Extremos por capítulos:** Los capítulos más positivos de toda la Biblia corresponden a los salmos de alabanza pura y celebración (Salmos 117, 150, 133, 100). Los capítulos con el sentimiento más bajo no son proféticos, sino narrativas históricas de guerra y tragedia. Por ejemplo, 1 Samuel 31 y 1 Crónicas 10 relatan la derrota y el suicidio del rey Saúl en batalla, mientras que Jeremías 41 describe una masacre política. VADER detecta correctamente la concentración de violencia, muerte y espadas en estos versos.
- **Evolución de sentimiento en Psalms:** La línea oscila notoriamente por encima y por debajo de la línea neutral (0.0). Esto refleja de manera matemática la estructura real del libro, el cual intercala constantemente Salmos de Lamento (donde el autor expresa profunda angustia, persecución y queja) con Salmos de Acción de Gracias (exaltación y victoria). Además, es notable cómo, a partir del capítulo 140, la volatilidad disminuye y los puntajes se disparan hacia arriba. Los últimos capítulos del libro (145 al 150) son puras alabanzas, culminando en el pico más alto de positividad de todo el libro.




Figure 14: Evolución de sentimiento en Psalms.

Conclusiones

A lo largo de este laboratorio, la aplicación de técnicas de Procesamiento de Lenguaje Natural (NLP) sobre el corpus de la Biblia permitió comprobar empíricamente las grandes diferencias estructurales y temáticas entre el Antiguo y el Nuevo Testamento. En primer lugar, el uso de un modelo orientado a objetos (OOP) facilitó enormemente el orden y la manipulación de la jerarquía de datos presente en la Biblia.

Uno de los hallazgos más importantes del desarrollo fue el impacto del desbalance de clases en los modelos estadísticos. Como se observó en el clasificador Naive Bayes, el hecho de que libros como Psalms tengan una cantidad tan superior de versículos genera un sesgo enorme, actuando como un imán para las predicciones cuando se evalúan frases genéricas. Esto demuestra que en minería de texto no basta con mirar el accuracy general, sino que herramientas como la matriz de confusión son vitales para entender cómo se equivoca realmente el modelo.

Por otro lado, la vectorización con TF-IDF y la reducción de dimensionalidad con PCA lograron capturar perfectamente el contexto de los textos. Se comprobó gráficamente que el Nuevo Testamento mantiene una homogeneidad léxica mucho mayor, lo que hace sentido por su corto periodo de escritura y temática centrada en Jesús. Esto fue respaldado por el análisis de sentimiento con VADER, que detectó un vocabulario mucho más positivo y enfocado en el amor, en claro contraste con la heterogeneidad y los picos negativos del Antiguo Testamento, marcados por relatos de guerras y juicios.

Finalmente, las pruebas con el generador de texto dejaron en evidencia el comportamiento de las cadenas de Markov y los N-Gramas: existe un punto de equilibrio necesario donde un n-grama muy bajo genera frases sin sentido, pero uno muy alto termina sobreajustándose (memorizando) y copiando el texto original. En general, las herramientas implementadas lograron extraer patrones claros, interpretables y cuantificables a partir de un texto histórico complejo.